

Probabilidade e Estatística

Prof. Douglas

1 de setembro de 2026

1 Introdução a Estatística

1.1 O que é a estatística?

- A Estatística envolve a coleta, organização, análise, interpretação e apresentação de dados.
- Seu propósito central é extrair conhecimento dos dados disponíveis.
- Finalidade: apoiar a tomada de decisões fundamentadas em evidências.
- Fornece técnicas para resumir informações, identificar padrões e compreender tendências.

1.2 Conceitos fundamentais

- A estatística envolve a coleta, organização, análise, interpretação e apresentação de dados
- Seu propósito central é extrair conhecimento
- População: Conjunto completo de elementos investigados
- Amostra: Subconjunto representativo da população
- Variável de interesse: Característica observada em cada indivíduo da amostra, que será analisada estatisticamente

1.3 Etapas da Análise Estatística

1. Definir a população de interesse
2. Estabelecer objetivos de pesquisa: investigar hipóteses, comparar grupos ou descrever fenômenos
3. Coleta de dados: por experimentos, questionários, observações ou fontes existentes
4. Organização dos dados: tabelas ou planilhas para facilitar análise
5. Análise dos dados:
 - Análise exploratória: compreensão inicial via gráficos e tabelas
 - Análise inferencial: tirar conclusões sobre a população

1.4 Temas da Estatística

- Estatística descritiva / análise exploratória
 - Apresentação clara e concisa dos resultados via gráficos e tabelas
- Probabilidade:
 - Ferramentas para lidar e quantificar a incerteza
- Inferência estatística:
 - Estimação dos parâmetros desconhecidos
 - Formulação e teste de hipóteses
 - Generalização dos resultados da amostra para a população

2 Organização dos Dados e Tipos de Variáveis

2.1 Tipos de Variáveis

1. Variáveis Qualitativas

- Definição: Descrevem categorias ou atributos e não representam medidas numéricas.
 - Nominais:
 - * Não possuem ordem natural
 - * As categorias apenas identificam grupos
 - * Exemplos: Sexo, estado civil, tipo sanguíneo, cor dos olhos, ...
 - Ordinais:
 - * Possuem uma ordem ou hierarquia
 - * A distância entre categorias não é conhecida
 - * Exemplos: Escolaridade, grau de satisfação, faixas de judô, medalhas olímpicas, ...

2. Variáveis Quantitativas

- Definição: Representam quantidades numéricas obtidas por medição ou contagem
 - Contínuas:
 - * Obtidas por medição
 - * Podem assumir qualquer valor dentro de um intervalo
 - * Exemplos: Altura, peso, temperatura, pressão arterial, ...
 - Discretas:
 - * Obtidas por contagem
 - * Assumem valores separados (geralmente inteiros)
 - * Exemplos: Números de filhos, de acidentes, de veículos, de consultas, ...

Observação: A classificação depende da forma como a variável é medida ou registrada, e não apenas do seu nome.

2.2 Organização dos Dados

- A organização de uma base de dados é crucial para garantir eficiência na manipulação e análise das informações. Siga as etapas abaixo
 1. Defina claramente o objetivo da base de dados: isso orientará as informações a serem armazenadas e a estrutura a ser adotada
 2. Utilize planilhas eletrônicas (Excel, Google Planilhas, Bloco de Notas, etc.) para facilitar a organização e o acesso aos dados.
 3. Descreva detalhadamente cada variável, especialmente se utilizar siglas ou abreviações, para garantir clareza e evitar ambiguidades.

2.2.1 Estrutura de uma Base de Dados

- Uma base de dados pode ser representada como uma matriz:

$$x = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

- Cada linha representa uma observação (ou repetição do experimento)
 - Cada coluna representa uma variável
 - n é o número de observações
 - p é o número de variáveis medidas
 - O elemento x_{ij} representa o valor da variável j na observação i
- Uma base de dados pode ser organizada em forma de tabela:

Aluno	Idade	Altura (cm)	Peso (kg)
1	20	170	68
2	22	175	72
3	19	168	65
4	21	180	80

- Cada linha representa uma observação (ou indivíduo)
- Cada coluna representa uma variável
- Matematicamente, essa base de dados pode ser representada como uma matriz:

$$x = \begin{pmatrix} 20 & 170 & 68 \\ 22 & 175 & 72 \\ 19 & 168 & 65 \\ 21 & 180 & 80 \end{pmatrix}$$

2.2.2 De onde vêm os dados?

1. Fontes Primárias:

- Dados coletados pelo próprio pesquisador para responder uma pergunta específica
- Exemplos: Questionários, entrevistas, experimentos, observação direta

2. Fontes Secundárias:

- Dados já existentes, produzidos anteriormente para outros objetivos.
- Exemplos: IBGE, DataSUS, prontuários, artigos científicos, big data
- Conceitos Fundamentais
 - Pesquisa: Processo sistemático de coleta, organização, análise e interpretação de dados para responder a uma pergunta científica
 - População: Conjunto completo de indivíduos ou unidades sobre os quais desejamos obter informações
 - Amostra: Subconjunto da população utilizado para realizar o estudo e tirar conclusões sobre o todo

3 Análise Exploratória de Dados

3.1 População e Amostra

- População – Conjunto completo de indivíduos ou unidades de interesse sobre os quais queremos obter informações.
- Amostra – Subconjunto selecionado da população, usado para obter informações e tirar conclusões sobre ela.
- Unidade Amostral – Cada elemento individual da amostra. Unidade sobre a qual as observações ou medições são realizadas.

3.2 Amostragem

- Probabilística
 - Envolve seleção aleatória, garantindo que cada elemento da população tenha uma chance conhecida de ser incluído na amostra
 - Considerado um método científico rigoroso para coleta de dados
- Não Probabilística
 - Depende da escolha deliberada dos elementos pelo pesquisador, baseada em critérios e julgamento, sem garantia de representatividade estatística

3.2.1 Métodos de Amostragem

- Aleatória Simples

- Definição: Todos os elementos da população possuem a mesma probabilidade de serem selecionados
- Como realizar:

- * Numere todos os elementos da população

$$U = \{1, 2, 3, \dots, N\}$$

N : Número de unidade amostral da população

n : Número de unidade amostral de amostras

- O sorteio pode ser:

- * Com reposição: o elemento retorna à população e pode ser sorteado novamente

- Número de amostras possíveis: N^n , logo:

$$P(U = u_i) = \frac{1}{N^n}$$

- * Sem reposição: o elemento não retorna e não poderá ser selecionado novamente

- Número de possíveis amostras:

$$C(N, n) = \binom{N}{n} = \frac{N!}{n!(N-n)!}$$

logo,

$$P(U = u_i) = \frac{1}{\binom{N}{n}}$$

- Observação: Uma combinação é uma seleção não ordenada de elementos

- Vantagens:

- * Simples de aplicar
- * Permite medir a precisão das estimativas
- * Propriedades estatísticas bem conhecidas

- Desvantagens:

- * Requer lista completa da população
- * Pode ser caro se a amostra for muito dispersa
- * Não utiliza informações auxiliares

- Qual deve ser o tamanho da amostra?

- * O tamanho da amostra da

- Sistemática

- Definição: Os elementos da população estão ordenados, e a seleção da amostra é realizada em intervalos regulares
- Etapas:
 1. Defina o tamanho da população (N)
 2. Defina o tamanho da amostra (n)
 3. Calcule o intervalo da seleção (IS)

$$IS = \frac{N}{n}$$
 4. Escolha aleatoriamente o primeiro elemento entre 1 e IS
 5. Selecione os demais elementos adicionado sucessivamente o intervalo IS
- Estratificada
 - Definição: Divisão da população U em H grupos disjuntos e homogêneos, conhecidos como estratos. Entre os estratos, existem diferenças significativas, evidenciando a heterogeneidade da população
 - Passos do procedimento:
 1. Selecionar uma amostra dentro de cada estrato, de forma independente
 2. Formar a amostra final unindo todas as amostras selecionadas nos estratos
 3. Dentro de cada estrato, podem ser usados diferentes métodos de coleta ou amostragem, conforme necessário
- Por Conglomerados
 - Definição:
 - * A população é dividida em grupos chamados conglomerados (ex.: bairros, escolas, hospitais)
 - * Alguns conglomerados são escolhidos aleatoriamente para formar a amostra
 - * A amostra consiste em todos os elementos dos conglomerados selecionados
 - Vantagens:
 1. Pode facilitar a coleta dos dados
 2. Conglomerados são grupos naturais dentro da população (família, departamentos, hospitais, etc.)
 3. Mais barato (menos deslocamento)
 - Desvantagens:
 - * Precisa de informação prévia sobre os conglomerados
 - * Mais complicado para estimar parâmetros de interesse

4 Distribuição de Frequências de Variáveis

- Tabelas de frequência: organização dos dados em formato tabular.
- Tipos de frequência: absoluta, relativa, percentual e acumulada.
- Representação Esquemática

4.1 Elementos de uma tabela

Tabela 1: Título da Tabela

Cabeçalho
Corpo da tabela
Rodapé (opcional)

Fonte ou observações complementares

- Título: deve responder às seguintes questões fundamentais
 - O quê? – Tema abordado (fato ou fenômeno estudado)
 - Onde? – Local de ocorrência ou observação
 - Quando? – Período ou época de registro
 - Quem? – Responsável pela pesquisa ou investigação
 - Por quê? – Relevância ou importância do estudo
- Cabeça: indica o conteúdo de cada coluna
- Corpo: formado pelas linhas e colunas
- Linhas: sequência horizontal de informações
- Colunas sequência vertical de informações
- Coluna Indicadora: Categorias ou descrições associadas aos dados
- Rodapé: notas explicativas, fontes e chamadas
- Fonte: instituição responsável pelos dados

4.2 Análise de Frequência para Variáveis Qualitativas

- Definições:
 - Classe – Cada uma das categorias possíveis que uma variável qualitativa pode assumir.
 - Frequência da classe (ou frequência absoluta) (f_a) – Número de observações que pertencem a uma determinada classe.
 - Frequência relativa da classe (f_r) – Razão entre a frequência da classe e o número total de observações.
 - Percentual da classe – Frequência relativa da classe multiplicada por 100.
- Cuidado com a Ordem das Categorias
 - Ao apresentar uma tabela de frequência ou um gráfico, é importante definir um critério claro para a ordem das categorias da variável
 - * Ordem alfabética – Organiza as categorias de forma neutra e padronizada
 - * Ordem por frequência – Organiza as categorias da maior para a menor frequência

- * Ordem lógica ou natural – Quando existe uma sequência natural (ex.: níveis de escolaridade)
- A escolha da ordem deve ser clara e consistente, pois pode influenciar a interpretação visual de tabelas e gráficos.

Tabela 2: Exemplo de dados de uma pesquisa com 15 alunos

Aluno	Sexo	Curso	Transporte	Dia da Semana
1	F	Estatística	Ônibus	Segunda
2	F	Computação	Ônibus	Quarta
3	F	Estatística	Ônibus	Sexta
4	F	Matemática	Ônibus	Terça
5	F	Computação	Bicicleta	Quinta
6	F	Estatística	Ônibus	Segunda
7	F	Matemática	Bicicleta	Quarta
8	F	Computação	Carro	Sexta
9	M	Matemática	Carro	Terça
10	M	Estatística	Bicicleta	Quinta
11	M	Computação	Carro	Segunda
12	M	Estatística	Carro	Quarta
13	M	Matemática	Ônibus	Sexta
14	M	Computação	Carro	Terça
15	M	Estatística	Ônibus	Quinta

Quando tem um parêntese (Ex.: $x_{(1)}$) significa que está sendo usado a ordem.

5 Medidas de Dispersão

- Objetivo: Fornecer informações sobre o quão afastados ou espalhados os valores estão em relação a media
- Quais são as e

5.1 Variância e Réplicas

- As réplicas permitem avaliar a variabilidade dos resultados dentro de cada tratamento
-

6 Probabilidade

- Probabilidade é uma forma matemática de avaliar possibilidades ou chances de algo acontecer
- A ideia de chance está presente em nossa vida desde muito cedo:
 - Jogos infantis (dominó)