

ANÁLISE EXPLORATÓRIA DE DADOS

Distribuição de frequências de variáveis quantitativas;

Prof. Douglas Toledo

12 de agosto de 2026

Conteúdo

- Construção de tabelas de frequência;
- Agrupamento de valores em classes;
- Cálculo de frequências relativas e acumuladas;
- Representação gráfica de variáveis quantitativas.



Tabelas de Frequência: Conceitos Básicos

- **Amplitude de classe:** tamanho de cada intervalo usado para agrupar os dados.

- **Notação de intervalos:**

$$a \leq x < b \Rightarrow [a, b) \text{ ou } a \vdash b$$

$$a < x \leq b \Rightarrow (a, b] \text{ ou } a \dashv b$$

- **Frequência:** número de ocorrências.
- **Frequência acumulada:** soma das frequências até a classe atual.

*Tabela da distribuição de renda
Morettin e Bussab (2017)*

Classes	n_i	%
4,00 – 8,00	10	27,78
8,00 – 12,00	12	33,33
12,00 – 16,00	8	22,22
16,00 – 20,00	5	13,89
20,00 – 24,00	1	2,78
Total	36	100,00



Tabelas de Dados: Importância das Classes

- Quando há muitos valores diferentes, como no caso ao lado, a análise individual se torna difícil.
- Agrupar os dados em classes torna a tabela mais clara e facilita a identificação de padrões.
- A escolha da amplitude das classes influencia diretamente na forma como os dados serão interpretados.

Tabela de frequência para a variável *peso* Magalhães e Lima (2002) (resumo)

Peso (kg)	Frequência
44	1
47	2
48	1
49	2
50	2
52	2
54	1
66	1
70	1
⋮	
87	1
95	1
Total geral	50



Gráfico de Barras: Não Recomendado




Figura: Gráfico de frequência para a variável peso Magalhães e Lima (2002).

Por que esse gráfico não é recomendado?

Problema

O gráfico de barras acima representa uma variável quantitativa contínua (*peso*) com muitos valores distintos.

Consequência

Isso gera um excesso de barras, dificultando a visualização e a interpretação dos dados.

Solução

A melhor prática é agrupar os dados em classes e utilizar um **histograma**, que mostra a distribuição com mais clareza.



Definindo o Tamanho das Classes

- **Objetivo:** facilitar a visualização e interpretação dos dados agrupando valores em intervalos.
- **Regra de Sturges:** fornece uma estimativa do número de classes com base no tamanho da amostra (n):

$$nc = 1 + 3,322 \cdot \log_{10}(n)$$

Obs.: o resultado deve ser sempre arredondado para cima.

- **Amplitude da Classe:** após determinar o número de classes (nc), calcula-se a amplitude de cada uma:

$$ac = \frac{X_{(n)} - X_{(1)}}{nc} = \frac{\max - \min}{nc}$$

- **Limitações da Regra:**
 - Pode gerar poucas classes em amostras pequenas;
 - Pode criar muitas classes em amostras grandes.



Definindo o Tamanho das Classes

- **Regra da Raiz Quadrada:** uma abordagem simples que estima o número de classes (nc) com base no tamanho da amostra (n):

$$nc = \sqrt{n}$$

Obs.: o resultado deve ser sempre arredondado para cima.

- **Amplitude da Classe:** calculada dividindo a amplitude total dos dados pelo número de classes:

$$ac = \frac{\max - \min}{nc}$$

- **Limitações:**

- Para amostras pequenas ($n < 30$), pode gerar poucas classes;
- Para amostras grandes, pode resultar em muitas classes.

- **Outros métodos:** existe, por exemplo, a **fórmula de Freedman-Diaconis**, que será vista mais adiante no curso, pois exige conceitos ainda não apresentados.

Definindo o Número de Classes

Por que isso é importante?

O número de classes influencia a forma como os dados são organizados e a facilidade de interpretação da distribuição.

Em geral:

- Poucas classes podem ocultar características importantes dos dados.
- Muitas classes podem dificultar a visualização da distribuição.
- O número de classes costuma depender do tamanho da amostra.



Definindo o Tamanho das Classes

- **Conhecimento especializado e literatura:**

Leve em conta o contexto do estudo e recomendações teóricas para definir as classes.

- **Classes com mesma amplitude:**

- Método mais comum e fácil de interpretar;
- A frequência é calculada com base nesse agrupamento;
- Evite classes com limites difíceis (como números fracionários ou muitos decimais).



Contexto do Exemplo

Durante uma aula prática de Estatística, foi realizado um experimento para medir o **tempo de reação** de oito estudantes ao tentar segurar uma régua logo após sua queda.

Os tempos observados (em segundos) foram:

0,5 0,7 0,8 1,0 1,1 1,3 1,5 1,5

Atividade

- 1 Determine o número de classes utilizando a **Regra de Sturges**.
- 2 Determine o número de classes utilizando a **Regra da Raiz Quadrada**.
- 3 Construa a distribuição de frequências pelos dois métodos.
- 4 Compare os resultados obtidos e discuta qual representação parece mais adequada.



Aplicando a Regra de Sturges

Variável **Tempo de reação (s)** ordenada:

0,5; 0,7; 0,8; 1,0; 1,1; 1,3; 1,5; 1,5

Informações iniciais:

- Tamanho da amostra: $n = 8$;
- Valor mínimo: 0,5;
- Valor máximo: 1,5.

Aplicando a **Regra de Sturges**:

$$nc = 1 + 3,3 \cdot \log(8) \approx 1 + 3,3 \cdot 0,90 \approx 3,98 \approx 4$$

$$ac = \frac{1,5 - 0,5}{4} = \frac{1,0}{4} = 0,25$$

Defina as classes iniciando em 0,5 com amplitude $ac = 0,25$.



Aplicando Regra da Raiz Quadrada

Aplicando a **Regra da Raiz Quadrada** para definir o número de classes:

- Tamanho da amostra: $n = 8$;
- Valor mínimo: 0,5;
- Valor máximo: 1,5.

$$nc = \sqrt{8} \approx 2,83 \approx 3$$

$$ac = \frac{1,5 - 0,5}{3} = \frac{1,0}{3} \approx 0,35$$

Defina as classes usando o valor inicial (mínimo) e a amplitude $ac \approx 0,35$.



Exemplo: definição das classes com duas regras

Regra de Sturges ($nc \approx 4$, $ac = 0,25$)

Classe	Intervalo	Freq.
1ª	[0,5 – 0,75)	2
2ª	[0,75 – 1,0)	1
3ª	[1,0 – 1,25)	2
4ª	[1,25 – 1,5]	3

Regra da Raiz Quadrada ($nc \approx 3$, $ac \approx 0,35$)

Classe	Intervalo	Freq.
1ª	[0,5 – 0,85)	3
2ª	[0,85 – 1,2)	2
3ª	[1,2 – 1,55]	3

Obs.: Note que, apesar das diferentes divisões, a soma das frequências é a mesma ($n = 8$), apenas distribuída de forma diferente entre as classes.



Discussão: dificuldades na definição das classes

As regras de **Sturges** e da **Raiz Quadrada** ajudam a definir classes, mas podem gerar limitações:

- **Distribuição desigual:** muitos dados concentrados em poucos intervalos, e outros quase vazios.
- **Poucas observações em algumas classes:** dificulta a interpretação da distribuição real.
- **Perda de detalhes:** classes amplas podem esconder padrões importantes.
- **Alternativa:** combinar regras com análise visual (como histogramas) e conhecimento do contexto.



Exemplo: análise da tabela Magalhães e Lima (2002)

- A tabela utiliza classes de **amplitude 10 kg** e entre **5 a 8 classes**, conforme a sugestão dos autores.

- **Reflexão:**

- Essa escolha facilita ou dificulta a interpretação?
- A frequência acumulada é útil aqui?
- Existem classes com baixa ou nenhuma frequência?

- **Dica:** Avaliar se os intervalos realmente ajudam a visualizar a distribuição dos dados.

Tabela: Tabela de frequência para a variável Peso.

Peso	n_i	f_i	f_{ac}
40,0 ┤ 50,0	8	0,16	0,16
50,0 ┤ 60,0	22	0,44	0,60
60,0 ┤ 70,0	8	0,16	0,76
70,0 ┤ 80,0	6	0,12	0,88
80,0 ┤ 90,0	5	0,10	0,98
90,0 ┤ 100,0	1	0,02	1,00
Total	50	1,00	



Gráficos para frequência



Representações visuais

Como ilustrar distribuições de frequência de forma clara e informativa.



Comparação dos Histogramas

Comparação entre os histogramas obtidos pelas duas regras:



Discussão: Qual regra representa melhor a distribuição dos dados?



Histograma da frequência absoluta




Figura: Histograma para a variável peso Magalhães e Lima (2002)

Interpretação: O histograma mostra a distribuição dos valores da variável peso. A escolha do número de classes influencia a clareza: classes muito amplas ocultam detalhes e classes estreitas geram ruído visual.


Alguns cuidados: Histograma

- Escolher adequadamente o número de classes ao agrupar dados contínuos.
- As barras do histograma não devem ser separadas, pois representam intervalos contínuos.
- O histograma enfatiza a continuidade dos dados por meio de barras justapostas.
- É útil para identificar a forma da distribuição e possíveis assimetrias.



Polígono de frequência: é necessário calcular o ponto médio das classes

- Representa a distribuição dos dados de forma contínua e suave.
- Facilita a comparação entre diferentes distribuições.
- Permite visualizar tendências e padrões com mais clareza do que o histograma, especialmente em sobreposição com outras variáveis.
- Útil para destacar picos, simetrias e assimetrias na distribuição.




Polígono de frequência para a variável peso Magalhães e Lima (2002)



Ogiva → limites das classes + frequência acumulada.

- Indica o acúmulo das frequências ao longo das classes.
- Permite identificar a proporção de observações abaixo de determinado valor.
- Útil para localizar a mediana, quartis e percentis.
- Boa opção para comparar distribuições e entender a tendência de crescimento dos dados.



Ogiva: frequência acumulada peso
Magalhães e Lima (2002)



Do Histograma ao Gráfico de Barras

O **histograma** representa dados **contínuos**, agrupados em intervalos, com barras **justapostas**.

O **gráfico de barras** representa dados **discretos ou categóricos**, com valores separados e barras **espaçadas**.



Gráfico para Variável Quantitativa Discreta

- O **gráfico de barras** é o mais utilizado para representar a frequência (absoluta ou relativa) de uma variável discreta.
- Cada valor possível da variável é colocado no eixo x .
- A altura da barra representa a frequência ou a probabilidade associada.
- Diferente do **histograma**, as barras devem ficar **separadas**, pois a variável discreta assume valores isolados, geralmente obtidos por contagem.
- Permite visualizar rapidamente a distribuição da variável.
- Também é possível usar o **gráfico de pizza**, mas deve-se ter cuidado: quando há muitos níveis, a leitura pode ficar difícil e pouco informativa.



Distribuição do Número de Filhos

Tabela: Distribuição do número de filhos na amostra proveniente da base de dados do livro (MAGALHÃES; LIMA, 2002)

Número de filhos	Frequência	%	% acumulado
1	28	56,00	56,00
2	14	28,00	84,00
3	6	12,00	96,00
4	1	2,00	98,00
7	1	2,00	100,00
Total	50		



Comparação de Gráficos de Distribuição




Gráfico de barras

Observação: O gráfico de barras é uma representação adequada para variáveis quantitativas discretas, enquanto o gráfico de pizza deve ser usado com cuidado quando há poucos níveis.




Gráfico de pizza



Gráfico de dispersão: relação entre duas variáveis quantitativas

- Permite observar visualmente a existência de associação entre as variáveis.
- Identifica tendências (ex: linear, exponencial) e padrões.
- Ajuda a detectar outliers e agrupamentos.
- Indicado para análises bivariadas como regressão e correlação.



Análise Bivariada: Dados

Relação entre o **número de redes sociais utilizadas** e as **horas de sono por noite**.

Redes sociais	Horas de sono
1	8
2	7
3	6
3	7
4	5
5	6
6	5

Atividade: Construa o gráfico de dispersão.



Gráfico de Dispersão






Gráfico de dispersão: Magalhães e Lima (2002)

A escala dos eixos pode alterar a percepção da relação entre variáveis!



Escala



Escala

Observação: Apesar de representarem os mesmos dados, a leitura e interpretação visual da relação entre altura e peso pode mudar.



Atividade Final: Analisando Variáveis Quantitativas

Uma pesquisa foi realizada com **200 estudantes da UEM**. Foram registradas as seguintes informações:

- **Número de irmãos;**
- **Idade;**
- **Altura;**
- **Peso;**
- **Renda familiar mensal.**

- 1 Classifique as variáveis.
- 2 Para quais variáveis seria adequado calcular a frequência acumulada? Dê um exemplo de interpretação
- 3 Qual é a **representação gráfica mais adequada** para cada variável?
- 4 Escolha um par de variáveis que possa ser utilizado em uma **análise bivariada**.
- 5 Qual gráfico seria adequado para representar essa relação?
- 6 Formule uma **pergunta estatística** que poderia ser investigada por meio dessa análise bivariada.



Considerações Finais

- **Agrupamento de dados:** organizar valores contínuos em classes facilita a interpretação.
- **Tabelas de frequência:** síntese numérica da distribuição dos dados.
- **Gráficos de frequência:** representação visual que complementa a análise:
 - **Histograma:** ideal para variáveis contínuas;
 - **Polígono de frequência:** evidencia tendências e comparações;
 - **Gráfico de dispersão:** útil para relacionar duas variáveis;
 - **Gráfico de barras:** representa a distribuição de variáveis qualitativas ou quantitativas discretas;
 - **Gráfico de pizza:** mostra a proporção de cada categoria; deve ser usado com cautela quando há muitas categorias;
 - **Box-plot:** apresenta posição, dispersão e possíveis outliers *(requer conceitos que serão abordados posteriormente)*.
- **Função da análise:**
 - **Uma variável:** descrever comportamento e distribuição de frequências;
 - **Duas ou mais variáveis:** explorar possíveis relações entre elas.



Referências

 DANTAS, Carlos Alberto Barbosa. **Probabilidade: Um Curso Introditório Vol. 10**. [S.I.]: Edusp, 2013.

 MAGALHÃES, Marcos Nascimento; LIMA, Antônio Carlos Pedroso De. **Noções de probabilidade e estatística**. [S.I.]: Editora da Universidade de São Paulo, 2002. v. 5.

 MEYER, Paul L. Probabilidade: aplicações à estatística. **2ª Edição–Tradução de Ruy de CB Lourenço Filho**, 2011.

 MORETTIN, Luiz Gonzaga. **Estatística básica: probabilidade e inferência: volume único**. [S.I.]: Pearson Prentice Hall, 2010.

 MORETTIN, Pedro A; BUSSAB, Wilton O. **Estatística básica**. [S.I.]: Saraiva Educação SA, 2017.

