

ANÁLISE EXPLORATÓRIA DE DADOS

Medidas de dispersão

Prof. Douglas Toledo

20 de agosto de 2026

- **Medidas de dispersão:**

- **Objetivo:** fornecer informações sobre **quão afastados** ou espalhados os valores estão em relação à média.

- **Quais são essas medidas?**

- Amplitude total.
- Variância.
- Desvio padrão.
- Desvio absoluto médio e mediano.
- Coeficiente de variação.



Renda dos brasileiros

Dados simulados de uma distribuição de binomial negativa




Figura: Média igual, variâncias diferentes $\Rightarrow$ homogeneidade diferente

Medidas de Dispersão

- As medidas de tendência central, como a **média**, descrevem a posição central dos dados, mas não mostram **o quanto os valores variam**.
- As **medidas de dispersão** quantificam a variabilidade dos dados em relação a um valor central.
- Permitem comparar o grau de **consistência** entre diferentes conjuntos de dados.
- **Menor dispersão** $\Rightarrow$ maior **homogeneidade**.
- **Maior dispersão** $\Rightarrow$ maior **heterogeneidade**.

Tendência central + Dispersão $\Rightarrow$ melhor compreensão dos dados



Variância e Réplicas

- As **réplicas** permitem avaliar a variabilidade dos resultados dentro de cada tratamento.
- Essa variabilidade é fundamental para avaliar a **consistência** dos resultados.
- Dois tratamentos podem apresentar médias semelhantes, mas variabilidades muito diferentes.



Por que quantificar a dispersão?

- **Incerteza:** Maior dispersão implica maior incerteza nas estimativas e conclusões.
- **Deteccção de outliers:** Auxilia na identificação de valores atípicos, que podem indicar erros ou fenômenos relevantes.
- **Homogeneidade:** Baixa dispersão indica maior consistência entre observações (maior confiabilidade experimental).
- **Controle de qualidade:** Fundamental para garantir estabilidade e padronização em processos industriais e experimentais.
- **Comparação entre grupos:** Permite avaliar diferenças reais entre populações, além das médias.



Por que precisamos de uma medida de dispersão?

A soma dos desvios em relação à média é sempre igual a zero:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Logo, a soma dos desvios **não é uma medida de dispersão**, pois os valores positivos e negativos se cancelam. Para evitar esse cancelamento, podemos:

eleva os desvios ao quadrado

ou

tomar o módulo dos desvios

Além disso, uma simples soma depende do número de observações. Para obter uma medida comparável entre conjuntos de diferentes tamanhos, calculamos a **média dos desvios ao quadrado**:



Amplitude Total

- A **amplitude** é a diferença entre o **maior** e o **menor** valor da variável:

$$A = \max(x) - \min(x) = x_{(n)} - x_{(1)}.$$

- Onde $x_{(n)}$ e $x_{(1)}$ são estatísticas de ordem, representando a última e a primeira posição na amostra, com os valores ordenados de forma crescente.
- A amplitude é expressa na mesma unidade de medida da variável.
- **Desvantagens:** A amplitude é sensível a outliers, pois é influenciada apenas pelos valores extremos do conjunto de dados.
- Medidas que consideram todos os dados tendem a fornecer uma descrição mais completa da variabilidade.



Desvio Médio

- **Definição:** Medida de dispersão que calcula a distância média dos dados em relação à média. É sensível a outliers, que podem distorcer sua interpretação.

- **Fórmula:**

$$\text{Desvio Médio} = \frac{1}{n} \sum_{i=1}^n |X_i - \bar{x}|$$

- **Exemplo:** Para os dados $[2, 4, 6, 100]$, calcular o desvio médio.
- *Observação:* Um valor extremo (100) aumenta bastante o desvio médio.



Desvio Mediano

- **Definição:** Mede a dispersão em torno da mediana, sendo menos sensível a outliers.

- **Fórmula:**

$$\text{Desvio Mediano} = \frac{1}{n} \sum_{i=1}^n |X_i - \text{md}|$$

- **Exemplo:** Para os dados $[2, 4, 6, 100]$, calcular o desvio mediano.
- *Observação:* O desvio mediano é menos distorcido pelo valor extremo (100).



Resolução: Desvio Médio vs Desvio Mediano

Desvio Médio

- Média: $\bar{x} = \frac{2+4+6+100}{4} = 28$
- Distâncias: $|2 - 28| = 26$,
 $|4 - 28| = 24$, $|6 - 28| = 22$,
 $|100 - 28| = 72$
- Soma:
 $26 + 24 + 22 + 72 = 144$
- Desvio Médio: $\frac{144}{4} = 36$

Desvio Mediano

- Mediana: $md = \frac{4+6}{2} = 5$
- Distâncias: $|2 - 5| = 3$,
 $|4 - 5| = 1$, $|6 - 5| = 1$,
 $|100 - 5| = 95$
- Soma: $3 + 1 + 1 + 95 = 100$
- Desvio Mediano: $\frac{100}{4} = 25$



Variância - Populacional

- **Variância populacional:** Mede a dispersão dos dados em torno da média, indicando o quão distantes os valores individuais estão do centro.

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

- A variância é sempre **positiva**, pois é o quadrado da diferença entre cada valor e a média.
- *Observação:* A variância utiliza o quadrado dos desvios para eliminar sinais negativos e enfatizar valores mais distantes da média.



Variância - Amostral

- **Variância amostral:** Calcula-se pela soma dos quadrados dos desvios em relação à média:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

- A explicação do denominador será abordada na parte de inferência estatística.



Variância - Unidade de Medida

- **Unidade de medida:** A variância possui a unidade da variável *ao quadrado*, pois calcula o quadrado dos desvios em relação à média.
 - Exemplo 1: Se os dados forem comprimentos em metros (m), a variância terá unidade m^2 .
 - Exemplo 2: Se os dados forem valores monetários em reais (R\$), a variância terá unidade $R\2 .



Exemplo: Renda familiar

Uma pesquisa foi realizada com uma amostra de estudantes de uma universidade para investigar a **renda familiar mensal**, expressa em salários mínimos. Foram selecionados dois grupos de estudantes:

- **Grupo A:**

2, 3, 5, 2, 3, 1, 2, 4, 1, 5

- **Grupo B:**

6, 2, 6, 5, 5, 5, 8, 8, 5

Atividade: Calcule a **variância** de cada grupo e compare os resultados.



Exemplo: Cálculo da Variância

- **Média do Grupo A:**

$$\bar{x} = \frac{2 + 3 + 5 + 2 + 3 + 1 + 2 + 4 + 1 + 5}{10} = 2.8 \text{ Salários}$$

- **Fórmula da variância amostral:**

$$S^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Passos para o cálculo:**

- 1 Subtrair a média de cada valor: $x_i - \bar{x}$;
- 2 Elevar cada diferença ao quadrado: $(x_i - \bar{x})^2$;
- 3 Somar todos os quadrados;
- 4 Dividir por $n - 1$.



Exemplo: Cálculo da Variância – Grupo A

Tabela: Cálculo da variância para o grupo A

Aluno	Renda (x_i)	$\bar{x}$	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	2	2.80	-0.80	0.64
2	3	2.80	0.20	0.04
3	5	2.80	2.20	4.84
4	2	2.80	-0.80	0.64
5	3	2.80	0.20	0.04
6	1	2.80	-1.80	3.24
7	2	2.80	-0.80	0.64
8	4	2.80	1.20	1.44
9	1	2.80	-1.80	3.24
10	5	2.80	2.20	4.84
Total	28	28	0	19.6

$$S^2 = \frac{19.6}{9} \approx 2.18 \text{ salários}^2$$




Exemplo: Grupo B - Cálculo da Variância

Tabela: Cálculo detalhado da variância para o grupo B

Aluno	x_i (Renda)	x_i^2	$\bar{x}$	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	6	36	5.56	0.44	0.20
2	2	4	5.56	-3.56	12.64
3	6	36	5.56	0.44	0.20
4	5	25	5.56	-0.56	0.31
5	5	25	5.56	-0.56	0.31
6	5	25	5.56	-0.56	0.31
7	8	64	5.56	2.44	5.98
8	8	64	5.56	2.44	5.98
9	5	25	5.56	-0.56	0.31
Total	50	304	-	0.00	26.22

- Cálculo da variância:

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \frac{1}{8} (304 - 9 \times 5.56^2) \approx 3.27 \text{ salários}$$



Desvio Padrão - Comparação entre Grupos

- O desvio padrão (S) é a raiz quadrada da variância:

$$S = \sqrt{S^2}$$

- **Vantagem:** Diferentemente da variância, o desvio padrão está na **mesma unidade de medida dos dados originais**, facilitando a interpretação da dispersão.
- **Grupo A:**

$$S^2 = 2.18 \text{ Salários}^2 \Rightarrow S = \sqrt{2.18} \approx 1.48 \text{ Salários}$$

- **Grupo B:**

$$S^2 = 3.27 \text{ Salários}^2 \Rightarrow S = \sqrt{3.27} \approx 1.81 \text{ Salários}$$

- **Interpretação:** O Grupo A apresenta menor variância, indicando maior homogeneidade dos dados em relação ao Grupo B.

Coeficiente de Variação (CV)

- **Definição:** O CV é uma medida relativa de dispersão que expressa o desvio padrão como uma porcentagem da média:

$$CV = 100\% \times \frac{S}{\bar{X}}$$

- **Uso:** Permite comparar a variabilidade entre diferentes conjuntos de dados, mesmo quando as médias são diferentes.
- **Interpretação:** Como o CV é adimensional e expresso em %, facilita a comparação direta entre grupos ou variáveis com unidades distintas.
- **Vantagem:** É uma medida relativa, sem unidade, tornando a avaliação da variabilidade mais intuitiva.



Interpretação do Coeficiente de Variação (CV)

- O CV expressa a dispersão relativa dos dados em relação à média e permite comparar a variabilidade entre diferentes grupos.
- **Faixas de interpretação:**
 - $0 \leq CV < 0.3$ (ou 0% a 30%): **Baixa variabilidade** – os dados estão relativamente próximos da média.
 - $0.3 \leq CV < 0.6$ (ou 30% a 60%): **Variabilidade moderada** – os dados apresentam dispersão considerável em torno da média.
 - $CV \geq 0.6$ (ou 60% ou mais): **Alta variabilidade** – os dados estão bastante dispersos em relação à média.
- **Observação:** As faixas são referenciais e podem variar conforme a área de aplicação.



Exemplo: Cálculo do Coeficiente de Variação (CV)

- **Grupo A:**

$$CV = 100 \times \frac{S}{\bar{x}} = 100 \times \frac{1.476}{2.8} \approx 52.71\%$$

- **Grupo B:**

$$CV = 100 \times \frac{S}{\bar{x}} = 100 \times \frac{1.811}{5.56} \approx 32.57\%$$

- **Interpretação:**

- O CV do grupo A (52,71%) indica maior variabilidade relativa da renda.
- O CV do grupo B (32,57%) indica menor variabilidade relativa da renda.



Conclusão — Comparação entre os Grupos

Resumo Estatístico:

Grupo	Q1	Q2	Q3	Média	Moda	Mín	Máx	S	CV (%)
A	1.5	2.5	4.5	2.8	2	1	5	1.48	52.71
B	5	5	7	5.56	5	2	8	1.81	32.57

Interpretação Comparativa:

- O **Grupo A** apresenta valores mais baixos e maior dispersão relativa (**CV = 52,71%**), indicando maior variabilidade dos resultados.
- O **Grupo B** apresenta valores mais altos e menor dispersão relativa (**CV = 32,57%**), indicando maior consistência dos resultados.
- A **média**, a **mediana** e a **moda** apresentam valores maiores no Grupo B, reforçando a diferença entre os grupos.



Recomendações

- **Investigar possíveis fontes de variabilidade** nos resultados observados.
- **Ampliar o tamanho amostral** e/ou realizar novas réplicas para aumentar a precisão das estimativas.
- **Avaliar e padronizar o protocolo experimental**, buscando reduzir fontes de variabilidade não desejada.
- Considerar conjuntamente o **efeito médio** e a **variabilidade dos resultados** na avaliação do tratamento.



Introdução ao Estudo de Glicemia

- A **variância** e o **desvio padrão** permitem quantificar a variabilidade dos dados em relação à média.
- O **desvio padrão** está na mesma unidade dos dados, facilitando a interpretação da dispersão.
- No estudo da glicemia, essas medidas permitem comparar a **variabilidade dos resultados** entre um tratamento e um grupo controle.

A seguir, analisaremos a média e a variabilidade dos grupos.



Exemplo: Estudo sobre Tratamento de Glicemia

Um estudo médico avaliou a eficácia de um novo tratamento para controle da glicemia (mg/dL) em pacientes com diabetes tipo 2. Foram incluídos dois grupos:

- **Grupo de Tratamento:** 100 pacientes recebendo o novo tratamento.
- **Grupo de Controle:** 100 pacientes mantendo o tratamento padrão.

O objetivo foi verificar se o tratamento reduz os níveis de glicemia em comparação com o grupo controle.

Perguntas para análise:

- Quem é a **unidade experimental**?
- Qual é a **medida de interesse**?
- Qual é o **tipo de variável**?
- Que **gráficos** podemos utilizar para visualizar os dados?
- Quais **medidas de posição e dispersão** podemos calcular?



Respostas ao Exemplo: Estudo de Glicemia

- **Unidade Experimental:** Pacientes do estudo (100 em cada grupo).
- **Medida de Interesse:** Nível de glicemia (mg/dL).
- **Tipo de Variável:** Quantitativa contínua, pois pode assumir qualquer valor dentro de um intervalo.
- **Gráficos sugeridos:** Histograma ou boxplot para comparar distribuições entre tratamento e controle.
- **Medidas de Posição e Dispersão:** Média, mediana, variância e desvio padrão para cada grupo, permitindo avaliar tendência central e variabilidade.



Análise Descritiva: Distribuição da Glicemia

Tabela: Medidas descritivas por grupo

Grupo	Média (mg/dL)	Desvio Padrão (S)	CV (%)
Controle	201.5	32.37	16.22
Tratamento	160.2	15.99	10.09

Interpretação:

- O grupo **Tratamento** apresenta menor média de glicemia (160,2 mg/dL) que o grupo **Controle** (201,5 mg/dL).
- O menor desvio padrão e o menor CV no grupo Tratamento indicam **menor variabilidade relativa**.
- Descritivamente, o grupo Tratamento apresenta valores de glicemia **mais baixos e mais concentrados**.


Os dados foram simulados para fins ilustrativos.



Análise Descritiva: Distribuição da Glicemia

Distribuição de Glicemia em Pacientes com Diabetes

Grupo  Controle  Tratamento




Análise Descritiva: Distribuição da Glicemia

- O histograma apresenta a distribuição dos níveis de glicemia nos dois grupos: **Tratamento** e **Controle**.
- As linhas verticais indicam as médias de cada grupo.
- Observa-se que o grupo de **Tratamento** possui:
 - Média mais baixa, indicando níveis médios de glicemia menores.
 - Distribuição mais concentrada, indicando menor variabilidade.
- O grupo **Controle** apresenta maior dispersão e média mais alta.



Análise Descritiva: Boxplot dos Níveis de Glicemia

Boxplot da Glicemia por Grupo



Análise Descritiva: Boxplot dos Níveis de Glicemia

- O boxplot mostra a distribuição dos níveis de glicemia nos grupos **Tratamento** e **Controle**.
- Observações sobre o grupo **Tratamento**:
 - Mediana mais baixa, indicando níveis centrais de glicemia menores.
 - Menor dispersão e ausência de valores extremos, sugerindo maior consistência.
- Observações sobre o grupo **Controle**:
 - Maior variabilidade nos valores.
 - Valores centrais mais altos e maior dispersão no grupo Controle.



Considerações Finais

- **Amplitude:**

- Fácil de calcular.
- Muito sensível a valores extremos (outliers).

- **Variância e Desvio Padrão:**

- Influenciados por valores extremos.
- Possuem propriedades matemáticas importantes, essenciais para inferência estatística.
- O **desvio padrão** mantém a mesma unidade dos dados, facilitando interpretação.

- **Coefficiente de Variação (CV):**

- Medida relativa e adimensional.
- Ideal para comparar variabilidade entre variáveis com unidades ou escalas diferentes.



Referências

-  DANTAS, Carlos Alberto Barbosa. **Probabilidade: Um Curso Introductorio Vol. 10**. [S.l.]: Edusp, 2013.
-  MAGALHÃES, Marcos Nascimento; LIMA, Antônio Carlos Pedroso De. **Noções de probabilidade e estatística**. [S.l.]: Editora da Universidade de São Paulo, 2002. v. 5.
-  MEYER, Paul L. Probabilidade: aplicações à estatística. **2ª Edição–Tradução de Ruy de CB Lourenço Filho**, 2011.
-  MORETTIN, Luiz Gonzaga. **Estatística básica: probabilidade e inferência: volume único**. [S.l.]: Pearson Prentice Hall, 2010.
-  MORETTIN, Pedro A; BUSSAB, Wilton O. **Estatística básica**. [S.l.]: Saraiva Educação SA, 2017.

