

ANÁLISE EXPLORATÓRIA DE DADOS

covariância, correlação entre variáveis quantitativas

Prof. Douglas Toledo

25 de agosto de 2026

Conteúdo da aula

- **Covariância (Cov)**

→ Mede como duas variáveis quantitativas **variam conjuntamente**.

- **Correlação de Pearson**

→ Mede a **força e direção da associação linear** entre duas variáveis (X, Y).

- **Exemplos de relações quantitativas:**

- Consumo de eletricidade $\leftrightarrow$ valor da conta de energia;
- Idade $\leftrightarrow$ tempo de reação a estímulos;
- Temperatura $\leftrightarrow$ velocidade de reação química.

Importante: correlação não implica causalidade!



Coeficiente de correlação de Pearson

- Assume valores no intervalo $-1 \leq \rho \leq 1$; ρ é dado por:
- Populacional:**

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

- Amostral:**

$$R_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$



Coeficiente de Correlação de Pearson

- A fórmula pode ser simplificada, não havendo diferença significativa entre as versões **populacional** e **amostral**, pois os fatores n se cancelam.
- No entanto, no **denominador**, a fórmula da variância não tem uma forma fechada, pois envolve somatórios.

$$\rho_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}$$
$$\rho_{XY} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{\sum_{i=1}^n X_i^2 - n\bar{X}^2} \sqrt{\sum_{i=1}^n Y_i^2 - n\bar{Y}^2}}$$



Coeficiente de Correlação de Pearson


O coeficiente de correlação de Pearson, ρ , mede a força e a direção da relação linear entre duas variáveis X e Y .

- ❶ $\rho > 0 \rightarrow$ correlação **positiva** entre X e Y ;
- ❷ $\rho < 0 \rightarrow$ correlação **negativa** entre X e Y ;
- ❸ $\rho \approx 1 \rightarrow$ correlação **fortemente positiva** entre X e Y ;
- ❹ $\rho \approx -1 \rightarrow$ correlação **fortemente negativa** entre X e Y ;
- ❺ $\rho \approx 0 \rightarrow$ correlação **fraca** (ou ausência de correlação linear) entre X e Y .
- ❻ **Observação:** Esta interpretação é válida apenas **na faixa de dados estudados**. Fora dessa amplitude, a relação entre X e Y pode mudar e não é possível prever com segurança.



Coeficiente de correlação de Pearson


Interpretação do Coeficiente de Correlação de Pearson



Coefficiente de correlação de Pearson

Tipos de Relação entre Duas Variáveis

Relação Linear Positiva




À medida que X aumenta, Y tende a aumentar.

Exemplo: altura e peso.

$$r > 0$$

Relação Linear Negativa




À medida que X aumenta, Y tende a diminuir.

Exemplo: idade e capacidade pulmonar.

$$r < 0$$

Relação Não Linear



Não há relação linear entre X e Y. Os valores de Y não seguem uma tendência linear.

Exemplo: tempo de estudo e desempenho (até certo ponto).

$$r \approx 0$$



Importante: O coeficiente de correlação de Pearson (r) mede apenas relações lineares.

Uma correlação próxima de zero não significa ausência de relação, apenas ausência de relação linear.



Correlação Espúria – Definição

- Uma **correlação espúria** ocorre quando existe uma associação estatística entre duas variáveis, **sem que haja relação causal** entre elas.
- Esse tipo de correlação pode surgir devido a:
 - influência de uma **terceira variável não observada**;
 - simples **coincidência**.
- Identificar correlações espúrias é essencial para **evitar conclusões equivocadas**.

Correlação não implica causalidade!



EXEMPLOS DE CORRELAÇÃO ESPÚRIA

Duas variáveis podem apresentar correlação apenas por coincidência ou pela influência de uma terceira variável.

1 Dados que “encontram” correlação




Encontramos essa correlação nos dados todo mundo raspando a cabeça já!




Lição: Dados podem sugerir relações que não fazem sentido lógico.

2 Picolé e afogamentos



Fator comum: calor no verão aumenta o consumo de picolés e também o número de afogamentos.

3 Nicolas Cage e afogamentos em piscinas



Os padrões das duas séries são muito semelhantes, resultando em correlação alta ($r \approx 0,8$), mas **não** existe relação causal.

✓ CORRELAÇÃO NÃO IMPLICA CAUSALIDADE!




Mensagem principal: Sempre investigue a presença de uma terceira variável ou de coincidência antes de concluir que duas variáveis estão causalmente relacionadas.



Correlação Espúria

- Década de 1930: aumento da população em cidades do leste da Alemanha e na Dinamarca.
- Ao mesmo tempo, observou-se um aumento no número de **cegonhas**.
- Sir Ronald Fisher reportou uma correlação de aproximadamente **0,9** entre as duas variáveis.
- Apesar da correlação forte, **não existe relação causal**.
- A explicação provável está em uma **terceira variável**:
mais áreas urbanizadas $\Rightarrow$ maior população & mais cegonhas.




Exemplo de correlação
espúria




Correlação Espúria – Cuidado com Interpretações

- O objetivo de Fisher era mostrar a necessidade de **cautela na interpretação** de resultados de correlação.
- O caso das cegonhas foi usado como um **exemplo de correlação espúria**.
- O fenômeno real: **migração para as cidades**
⇒ mais casas construídas.
- As **cegonhas passaram a fazer ninhos nas chaminés** dessas novas construções.



PIB vs Temperatura



Exemplo de Correlação Espúria: PIB per capita $\times$ Temperatura

- Observa-se, em alguns estudos, que países com **maior PIB per capita** tendem a estar em regiões de **clima mais frio**.
- Isso pode sugerir, de forma enganosa, que **temperatura influencia diretamente a riqueza**.
- Na realidade, trata-se de uma **correlação espúria**:
 - Fatores históricos, geográficos e políticos explicam melhor o desenvolvimento econômico;
 - A temperatura é apenas uma variável correlacionada, não a causa.



Exemplo 1: Dados


Relação entre o **número de redes sociais utilizadas** e as **horas de sono por noite**.

Redes sociais (X)	Horas de sono (Y)
1	8
2	7
3	6
3	7
4	5
5	6
6	5

Atividade: Calcule o coeficiente de correlação de Person.



Gráfico de Dispersão



- Olhando para esse gráfico, vocês acham que existe associação?"
- A associação parece positiva ou negativa?
- Ela parece forte ou fraca?



Tabela de Dados: Redes Sociais e Horas de Sono

Tabela de Cálculos para Correlação de Pearson

Aluno	$x_i = \text{Redes}$	$y_i = \text{Sono}$	$x_i y_i$	x_i^2	y_i^2
1					
2					
3					
4					
5					
6					
7					
Total					

Atividade: Complete a tabela, calcule o **coeficiente de correlação de Pearson** e construa o **gráfico de dispersão** para estas variáveis.



Tabela de Dados: Redes Sociais e Horas de Sono

Tabela de Cálculos para Correlação de Pearson

Aluno	$x_i = \text{Redes}$	$y_i = \text{Sono}$	$x_i y_i$	x_i^2	y_i^2
1	1	8	8	1	64
2	2	7	14	4	49
3	3	6	18	9	36
4	3	7	21	9	49
5	4	5	20	16	25
6	5	6	30	25	36
7	6	5	30	36	25
Total	24	44	141	100	284

Atividade: Calcule o **coeficiente de correlação de Pearson** e construa o **gráfico de dispersão** para estas variáveis.



Exemplo: Correlação de Pearson

$$r_{XY} = \frac{\sum X_i Y_i - n \bar{X} \bar{Y}}{\sqrt{\sum X_i^2 - n \bar{X}^2} \sqrt{\sum Y_i^2 - n \bar{Y}^2}}$$
$$r_{XY} \approx \frac{141 - 7(3,43)(6,29)}{\sqrt{100 - 7(3,43)^2} \sqrt{284 - 7(6,29)^2}}$$
$$r_{XY} \approx \frac{-10,02}{\sqrt{17,65} \sqrt{7,05}} = \frac{-10,02}{11,15} \approx \boxed{-0,9}$$

- **Conclusão:** A correlação de aproximadamente $r = -0,90$ indica uma **forte associação linear negativa** entre o número de redes sociais utilizadas e as horas de sono.
- Nesta amostra, quanto maior o número de redes sociais utilizadas, **menor tende a ser o número de horas de sono.**



Exemplo 2: Correlação de Pearson

- Investigar se há associação entre **pressão arterial sistólica** e **Índice de Massa Corporal (IMC)**.
- **Pressão arterial sistólica**: pressão exercida pelo coração durante a contração.
- **IMC**: medida que relaciona **peso e altura** de uma pessoa.
- Quais variáveis precisamos coletar para este estudo?



Medida de pressão arterial



Exemplo: Correlação de Pearson

- Considere os dados a seguir:

Paciente	$y_i = \text{IMC}$	$x_i = \text{Pressão Sistólica}$
1	20	136
2	33	168
3	32	164
4	35	160
5	25	149
6	29	154
7	26	160

- Calcule a correlação de Pearson entre os dados de IMC e pressão sistólica.




Figura: Gráfico da relação entre IMC e Pressão Sistólica



Tabela de Dados: IMC e Pressão Sistólica

Tabela de Cálculos para Correlação de Pearson

Paciente	$x_i = \text{IMC}$	$y_i = \text{Pressão}$	$x_i y_i$	x_i^2	y_i^2
1	20	136	2720	400	18496
2	33	168	5544	1089	28224
3	32	164	5248	1024	26896
4	35	160	5600	1225	25600
5	25	149	3725	625	22201
6	29	154	4466	841	23716
7	26	160	4160	676	25600
Total	200	1091	31463	5880	170733

Atividade: Calcule o **coeficiente de correlação de Pearson** e construa o **gráfico de dispersão** para estas variáveis.




Exemplo: Correlação de Pearson

$$\rho_{XY} \approx \frac{31463 - 7(28,57)(155,86)}{\sqrt{5880 - 7(28,57)^2} \sqrt{170733 - 7(155,86)^2}}$$
$$\rho_{XY} \approx \frac{292,56}{337,90} \approx 0,87$$

- **Conclusão:** A correlação de aproximadamente $r = 0,87$ indica uma forte associação linear positiva entre o IMC e a pressão sistólica.



Pressão X IMC



Outros Tipos de Correlação

- A **correlação de Pearson** mede o grau de **associação linear** entre variáveis.
- **Limitação**: não captura associações **não lineares**.
- Outras medidas de correlação podem ser mais adequadas dependendo do contexto:
 - **Correlação de Spearman**: associações **monotônicas** entre variáveis.
 - **Correlação de Kendall**: baseada na **concordância e discordância** entre pares de observações.
- O **teste de hipótese para correlação** será abordado na seção de **Inferência Estatística**.



Considerações Finais

Covariância (Cov)

- Mede como duas variáveis quantitativas variam conjuntamente.
- O sinal indica se as variáveis tendem a variar na **mesma direção** ou em **direções opostas**.

Correlação de Pearson (r)

- Mede a **força e a direção da associação linear** entre duas variáveis quantitativas.
- Assume valores entre -1 e 1 .
- $r > 0$: associação linear positiva.
- $r < 0$: associação linear negativa.
- $|r|$ próximo de 1 : associação linear forte.
- $|r|$ próximo de 0 : associação linear fraca ou inexistente.

Lembre-se!

Correlação não implica causalidade.

Referências

 DANTAS, Carlos Alberto Barbosa. **Probabilidade: Um Curso Introdotório Vol. 10**. [S.I.]: Edusp, 2013.

 MAGALHÃES, Marcos Nascimento; LIMA, Antônio Carlos Pedroso De. **Noções de probabilidade e estatística**. [S.I.]: Editora da Universidade de São Paulo, 2002. v. 5.

 MEYER, Paul L. Probabilidade: aplicações à estatística. **2ª Edição–Tradução de Ruy de CB Lourenço Filho**, 2011.

 MORETTIN, Luiz Gonzaga. **Estatística básica: probabilidade e inferência: volume único**. [S.I.]: Pearson Prentice Hall, 2010.

 MORETTIN, Pedro A; BUSSAB, Wilton O. **Estatística básica**. [S.I.]: Saraiva Educação SA, 2017.

